

# Giochi per Reti Profonde

David Vencato

Università di Pisa

10 Ottobre 2023



UNIVERSITÀ DI PISA

- 1 Gioco di apprendimento a un livello
- 2 Gioco per reti neurali
- 3 Problema parziale e punti KKT
- 4 Approfondimento per DLG

## 1 Gioco di apprendimento a un livello

## 2 Gioco per reti neurali

## 3 Problema parziale e punti KKT

## 4 Approfondimento per DLG

## Definizione 1

*Un gioco simultaneo a una mossa è un gioco nel quale ci sono:*

- ① *un insieme di  $N$  giocatori;*
- ② *un insieme  $\Sigma_i$  (finito o infinito) di azioni per ogni giocatore  $i = 1, \dots, N$ . Si definisce inoltre l'insieme delle azioni congiunte  $\Sigma = \prod_{i=1}^N \Sigma_i$ ;*
- ③ *una funzione di utilità per ogni giocatore  $u_i : \Sigma \rightarrow \mathbb{R}$ .*

*In un gioco simultaneo a una mossa ogni giocatore deve fare la propria scelta senza conoscere quella degli altri giocatori.*

## Definizione 2

*Il "supervised learning" o apprendimento supervisionato è una classe di problemi dove si ha un insieme di dati  $\{(x_t, y_t)\}_{t=1}^T \in \mathcal{X} \times \mathcal{Y}$  e si vuole "imparare" una funzione predittiva  $h : \mathcal{X} \rightarrow \mathcal{Y}$  (chiamato anche predittore).*

Ipotesi sul modello:

- ①  $\mathcal{X} = \mathbb{R}^m$  e  $\mathcal{Y} = \mathbb{R}^n$ ;
- ② lineare: il predittore è del tipo  $h(x) = \phi(\theta x)$  dove  $\theta$  è una matrice  $n \times m$  che rappresenta i parametri "allenabili" del modello e  $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$  la funzione output;

### Definizione 3

*Il problema di apprendimento a un livello (OLP) si basa su una funzione perdita  $l : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$  che è convessa e differenziabile nel primo argomento.*

*Siano  $l_t(z) = l(z, y_t)$  e  $L_t(\theta) = l_t(\theta x_t)$ .*

*Per allenare il modello si deve minimizzare la funzione  $L(\theta) = T^{-1} \sum_{t=1}^T L_t(\theta)$ .*

## Definizione 4

*Il gioco di apprendimento a un livello (OLG) è un gioco simultaneo a una mossa con le seguenti caratteristiche:*

- ① *ci sono due giocatori: un protagonista  $p$  e un antagonista  $a$ ;*
- ②  *$p$  sceglie la matrice  $\theta \in \mathbb{R}^m \times \mathbb{R}^n$ ;  $a$  sceglie  $\{a_t, b_t\}_{t=1}^T$  con  $a_t \in \mathbb{R}^n$  e  $b_t \in \mathbb{R}$  tali che  $a_t^T z + b_t \leq l_t(z) \forall z \in \mathbb{R}^n$ ;*
- ③ *data un'azione congiunta  $(\theta, \{a_t, b_t\}_{t=1}^T)$ , la funzione di utilità dell'antagonista è  $U^a = T^{-1} \sum_{t=1}^T a_t^T \theta x_t + b_t$  mentre quella del protagonista è  $U_p = -U_a$ .*



## Caratteristiche del gioco:

- ① somma zero con azioni continue;
- ② se  $\tilde{\sigma}^P = \theta$  denota l'azione del protagonista e  $\tilde{\sigma}^a = \{a_t, b_t\}_{t=1}^T$  quella dell'antagonista, allora l'azione congiunta  $(\tilde{\sigma}^P, \tilde{\sigma}^a)$  è un equilibrio di Nash se  $U_P(\tilde{\sigma}^P, \tilde{\sigma}^a) \geq U_P(\sigma^P, \tilde{\sigma}^a) \forall \sigma^P$  e  $U_a(\tilde{\sigma}^P, \tilde{\sigma}^a) \geq U_a(\tilde{\sigma}^P, \sigma^a) \forall \sigma^a$ .

## Lemma 1

*L'azione congiunta  $\sigma = (\theta, \{a_t, b_t\}_{t=1}^T)$  è un equilibrio di Nash per OLG se e soltanto se  $l_t(\theta x_t) = a_t^T \theta x_t + b_t$ ,  $a_t = \nabla l_t(g)|_{g=\theta x_t}$  (miglior risposta dell'antagonista) e  $T^{-1} \sum_{t=1}^T a_t x_t^T = 0$  (miglior risposta del protagonista).*

# Dimostrazione Lemma

Vediamo  $\implies$  (l'altro senso è analogo):

- Per ipotesi  $a_t^T z + b_t \leq l_t(z) \quad \forall z \in \mathbb{R}^n$  dunque  
 $l_t(\theta x_t) = a_t^T \theta x_t + b_t$  è l'utilità massima per  $a$ .  
 $l_t$  è convessa e differenziabile allora  $\exists!$   $h(g)$  affine che è uguale  
a  $l_t$  in un punto e minore o uguale altrove, cioè  
 $h(g) = \nabla l_t(\theta x_t)(g - \theta x_t) + l_t(\theta x_t), \quad a_t = \nabla l_t(g)|_{g=\theta x_t}$ .
- $U^p = -T^{-1} \sum_{t=1}^T a_t^T \theta x_t + b_t$ . Facendo  
 $\nabla_{\theta} U^p = -T^{-1} \sum_{t=1}^T a_t x_t^T = 0$  otteniamo il massimo di  
 $U^p$ . □

## Teorema 1

*Se  $(\theta^*, \{a_t, b_t\}_{t=1}^T)$  è un equilibrio di Nash di OLG, allora  $\theta^*$  è un punto di minimo globale di OLP. Viceversa, se  $\theta^*$  è un punto di minimo globale di OLP, allora esiste una strategia dell'antagonista  $\{a_t, b_t\}_{t=1}^T$  tale che  $(\theta^*, \{a_t, b_t\}_{t=1}^T)$  è un equilibrio di Nash di OLG.*

# Dimostrazione Teorema

$\implies$ : Per quanto visto nel lemma , si deve avere

$$L(\theta^*) = T^{-1} \sum_{t=1}^T a_t^T \theta^* x_t + b_t, \quad a_t = \nabla l_t(g)|_{g=\theta^* x_t} \text{ e}$$

$$T^{-1} \sum_{t=1}^T a_t x_t^T = 0. \text{ Ultime due equazioni:}$$

$$T^{-1} \sum_{t=1}^T \nabla l_t(g)|_{g=\theta^* x_t} x_t^T = 0.$$

Ma il membro di sinistra è  $\nabla L(\theta^*)$  e dunque  $\nabla L(\theta^*) = 0$ .  
 $L$  convessa e differenziabile, allora  $\theta^*$  minimo globale.

# Dimostrazione Teorema

$\Leftarrow$ : L'antagonista per fare la risposta migliore a  $\theta^*$  deve scegliere  $a_t := \nabla l_t(g)|_{g=\theta^*x_t}$  e  $b_t = l_t(\theta^*x_t) - a_t^T \theta^*x_t$ . Allora, dato che  $\theta^*$  è minimo globale:

$$0 = \nabla L(\theta^*) = T^{-1} \sum_{t=1}^T \nabla L_t(\theta^*) = T^{-1} \sum_{t=1}^T (\nabla l_t(g)|_{g=\theta^*x_t}) x_t^T = T^{-1} \sum_{t=1}^T a_t x_t^T.$$

Per il lemma, anche  $\theta^*$  è la risposta migliore e allora si ha un equilibrio di Nash. □

Fino ad ora abbiamo ignorato la complessità del modello. Per questo introduciamo un vincolo  $\theta \in \Theta$  per un qualche insieme convesso  $\Theta$ .

Fino ad ora abbiamo ignorato la complessità del modello. Per questo introduciamo un vincolo  $\theta \in \Theta$  per un qualche insieme convesso  $\Theta$ .

### Definizione 5

*Si definisce il problema di apprendimento a un livello vincolato (OCP) un OLP al quale si aggiunge un vincolo di ottimizzazione  $\theta \in \Theta$ .*

### Definizione 6

*Si definisce il gioco di apprendimento a un livello vincolato (OCG) un OLG al quale si aggiunge un vincolo di ottimizzazione  $\theta \in \Theta$ .*



Supponiamo che  $\Theta$  sia un politopo cioè un'intersezione finita di semispazi. Allora,  $\Theta$  è esprimibile con un insieme finito  $J$  di funzioni affini, tale per cui  $\theta \in \Theta$  se e soltanto se  $j(\theta) \leq 0 \ \forall j \in J$ .

Supponiamo che  $\Theta$  sia un politopo cioè un'intersezione finita di semispazi. Allora,  $\Theta$  è esprimibile con un insieme finito  $J$  di funzioni affini, tale per cui  $\theta \in \Theta$  se e soltanto se  $j(\theta) \leq 0 \ \forall j \in J$ .

## Lemma 2

*$L$  è convessa e differenziabile, dunque condizioni necessari e sufficienti (condizioni KKT) affinché  $\theta^* \in \operatorname{argmin}_{\theta \in \Theta} L(\theta)$  è che esista  $\{\mu_j\}_{j \in J}$  tale che  $\forall j \in J$ :*

$$\begin{cases} \mu_j \geq 0 \\ \mu_j j(\theta^*) = 0 \\ j(\theta^*) \leq 0 \\ \sum_{j \in J} \mu_j \nabla j(\theta^*) = -\nabla L(\theta^*) \end{cases}$$

### Lemma 3

*L'azione congiunta  $\sigma = (\theta, \{a_t, b_t\}_{t=1}^T)$  è un equilibrio di Nash per OCG se e soltanto se  $l_t(\theta x_t) = a_t^T \theta x_t + b_t$ ,  $a_t = \nabla l_t(g)|_{g=\theta x_t}$  (miglior risposta dell'antagonista), e esiste  $\{\mu_j\}_{j \in J}$  tale che  $\forall j \in J$ :*

$$\begin{cases} \mu_j \geq 0 \\ \mu_j j(\theta) = 0 \\ j(\theta) \leq 0 \\ \sum_{j \in J} \mu_j \nabla j(\theta) = -T^{-1} \sum_{t=1}^T a_t x_t^T \text{ (miglior risposta protagonista)} \end{cases}$$

## Teorema 2

*Se  $(\theta^*, \{a_t, b_t\}_{t=1}^T)$  è un equilibrio di Nash di OCG, allora  $\theta^*$  è un punto di minimo globale con restrizione di OCP. Viceversa, se  $\theta^*$  è un punto di minimo globale con restrizione di OCP, allora esiste una strategia dell'antagonista  $\{a_t, b_t\}_{t=1}^T$  tale che  $(\theta^*, \{a_t, b_t\}_{t=1}^T)$  è un equilibrio di Nash di OCG.*

- 1 Gioco di apprendimento a un livello
- 2 Gioco per reti neurali
- 3 Problema parziale e punti KKT
- 4 Approfondimento per DLG

## Definizione 7

*Un grafo  $G$  è una coppia  $(V, E)$  dove  $V$  è l'insieme dei vertici ed  $E \subset V \times V$  quello degli archi. Se, inoltre, gli archi sono orientati allora si parla di grafo diretto. (Ben definiti vertice iniziale e finale).*

## Definizione 7

*Un grafo  $G$  è una coppia  $(V, E)$  dove  $V$  è l'insieme dei vertici ed  $E \subset V \times V$  quello degli archi. Se, inoltre, gli archi sono orientati allora si parla di grafo diretto. (Ben definiti vertice iniziale e finale).*

## Definizione 8

*Sia  $G$  un grafo diretto. Allora un percorso in  $G$  è una sequenza di archi  $(e_1, \dots, e_k)$  tale che il vertice finale di  $e_i$  è anche il vertice iniziale di  $e_{i+1} \forall i = 1, \dots, k - 1$ . Se vale anche che il vertice finale di  $e_k$  coincide col vertice iniziale di  $e_1$  allora si parla di ciclo. Un grafo diretto senza cicli è detto aciclico.*

## Definizione 9

*Una rete neurale feed-forward è una quintupla  $N = (V, E, I, O, F)$  dove  $(V, E)$  è un grafo diretto aciclico,  $I = \{i_1, \dots, i_m\} \subset V$  è l'insieme dei vertici di input,  $O = \{o_1, \dots, o_n\} \subset V$  è l'insieme dei vertici di output e  $F = \{f_v : \mathbb{R} \rightarrow \mathbb{R} \mid v \in V\}$  è l'insieme delle funzioni di attivazione. I parametri allenabili sono dati da  $\theta : E \rightarrow \mathbb{R}$ .*

*Ipotesi aggiuntive:*

- *non ci sono archi entranti nei vertici di input;*
- *non ci sono archi uscenti dai vertici di output.*



## Considerazioni:

- un grafo diretto aciclico induce un ordine parziale  $\leq$  sui vertici:  $u \leq v$  se e soltanto se esiste un percorso da  $u$  a  $v$ ;  
 $\forall v \in V, E_v := \{(u, u') \in E : u' = v\}$
- La rete neurale è "collegata" al set dei dati di allenamento assumendo che  $|I| = m$  (il numero dei vertici di input corrisponde al numero di caratteristiche degli input dell'apprendimento supervisionato) e  $|O| = n$  (il numero di vertici di output è uguale alla dimensione degli output del supervised learning).

# Funzionamento della rete neurale

Sia  $x_t \in R^m$  un valore input di allenamento. La rete neurale feed-forward lavora creando funzioni  $c_t$  che assegnano valori a ogni vertice nel seguente modo:

$$c_t(i_k, \theta) = f_{i_k}((x_t)_k), \quad i_k \in I$$

$$c_t(v, \theta) = f_v(\sum_{u:(u,v) \in E} c_t(u, \theta)\theta(u, v)), \quad v \in V - I.$$

Denotiamo con  $c_t(o, \theta)$  il vettore dei valori dei vertici di output (i.e.  $(c_t(o, \theta))_k := c_t(o_k, \theta)$  con  $o_k \in O$ ).

Per imporre vincoli a  $\theta$  lo facciamo in questo modo:  $\forall v \in V - I$  i parametri  $\theta$  ristretti a  $E_v$  devono stare in un insieme  $\Theta_v \subset \mathbb{R}^{E_v}$ , ponendo  $\Theta := \prod_{v \in V - I} \Theta_v$ .

Per imporre vincoli a  $\theta$  lo facciamo in questo modo:  $\forall v \in V - I$  i parametri  $\theta$  ristretti a  $E_v$  devono stare in un insieme  $\Theta_v \subset \mathbb{R}^{E_v}$ , ponendo  $\Theta := \prod_{v \in V - I} \Theta_v$ .

## Definizione 10

*Data una funzione di perdita  $l(z, y)$  che è convessa nel primo argomento e soddisfa  $0 \leq l(z, y) \leq \infty \forall z \in R^n$ , si definisce  $l_t(z) = l(z, y_t)$  e  $L_t(\theta) = l_t(c_t(o, \theta))$ . Il "problema di allenamento" è trovare  $\theta \in \Theta$  che minimizza  $L(\theta) = T^{-1} \sum_{t=1}^T L_t(\theta)$  (si parla di "Deep Learning Problem").*

# Deep Learning Game

Vogliamo definire un gioco simultaneo a una mossa che richiami il DLP. Chiamiamo questo gioco "Deep learning game" (DLG). Definiamo i giocatori, l'insieme delle azioni e le funzioni di utilità:

# Deep Learning Game

Vogliamo definire un gioco simultaneo a una mossa che richiami il DLP. Chiamiamo questo gioco "Deep learning game" (DLG).

Definiamo i giocatori, l'insieme delle azioni e le funzioni di utilità:

- *Giocatori*: per ogni vertice  $v \in V - I$  c'è un protagonista  $p$ ; per ogni vertice  $v \in V$  c'è uno zanni  $s_v$  (un agente che opera per il proprio interesse); un antagonista  $a$ .

# Deep Learning Game

Vogliamo definire un gioco simultaneo a una mossa che richiami il DLP. Chiamiamo questo gioco "Deep learning game" (DLG).

Definiamo i giocatori, l'insieme delle azioni e le funzioni di utilità:

- *Giocatori*: per ogni vertice  $v \in V - I$  c'è un protagonista  $p$ ; per ogni vertice  $v \in V$  c'è uno zanni  $s_v$  (un agente che opera per il proprio interesse); un antagonista  $a$ .
- *Azioni*: il protagonista nel vertice  $v$  sceglie una funzione parametro  $\theta_v \in \Theta_v$ . L'antagonista sceglie un insieme di vettori  $T$  e scalari  $\{a_t, b_t\}_{t=1}^T$  con  $a_t \in \mathbb{R}^n$  e  $b_t \in \mathbb{R}$  tali che  $a_t^T z + b_t \leq l_t(z) \forall z \in \mathbb{R}^n$ . Allo stesso modo, ogni zanni  $s_v$  sceglie un insieme di  $2T$  scalari  $\{q_{vt}, d_{vt}\}_{t=1}^T$  con  $q_{vt} \in \mathbb{R}$  e  $d_{vt} \in \mathbb{R}$  tali che  $q_{vt}z + d_{vt} \leq f_v(z) \forall z \in \mathbb{R}$ .

# Deep Learning Game

- *Funzioni di utilità*: consideriamo un'azione congiunta  $\sigma = (\theta, \{a_t, b_t\}_{t=1}^T, \{q_{vt}, d_{vt}\})$ .

**Utilità per gli zanni**:  $t$ -esimo elemento del training set è:

$$U_{it}^s(\sigma) = d_{it} + q_{it}x_{it}, \quad i \in I$$

$$U_{vt}^s(\sigma) = d_{vt} + q_{vt} \sum_{u:(u,v) \in E} U_{tu}^s(\sigma) \theta(u, v), \quad v \in V - I.$$

Dunque, fissato  $v \in V$ , la funzione utilità totale per lo zanni  $s_v$  è data da  $U_v^s(\sigma) = \sum_{t=1}^T U_{vt}^s(\sigma)$ .

**Utilità per l'antagonista**:  $U^a = T^{-1} \sum_{t=1}^T U_t^a$  dove  $U_t^a(\sigma) = b_t + \sum_{k=1}^n a_{kt} U_{o_k t}^s(\sigma)$ .

**Utilità per i protagonisti**:  $U^p(\sigma) = -U^a(\sigma)$ .



## Lemma 4

*Data un'azione dei protagonisti  $\theta$ , esiste un'unica azione congiunta  $\sigma = (\theta, \{a_t, b_t\}_{t=1}^T, \{q_{vt}, d_{vt}\})$  nella quale gli zanni e l'antagonista giocano le loro migliori risposte a  $\theta$  ( $\sigma$  è la scelta congiunta espansa per  $\theta$ ).*

*Inoltre,  $U_p(\sigma) = -L(\theta)$ ,  $\nabla_{\theta} U^p(\sigma) = -\nabla L(\theta)$ , e dato un protagonista in  $v \in V - I$ , se teniamo le scelte di ogni altro agente fisse,  $U^p(\sigma)$  è una funzione affine rispetto alla strategia del protagonista in  $v$ .*

## Lemma 4

*Data un'azione dei protagonisti  $\theta$ , esiste un'unica azione congiunta  $\sigma = (\theta, \{a_t, b_t\}_{t=1}^T, \{q_{vt}, d_{vt}\})$  nella quale gli zanni e l'antagonista giocano le loro migliori risposte a  $\theta$  ( $\sigma$  è la scelta congiunta espansa per  $\theta$ ).*

*Inoltre,  $U_p(\sigma) = -L(\theta)$ ,  $\nabla_{\theta} U^p(\sigma) = -\nabla L(\theta)$ , e dato un protagonista in  $v \in V - I$ , se teniamo le scelte di ogni altro agente fisse,  $U^p(\sigma)$  è una funzione affine rispetto alla strategia del protagonista in  $v$ .*

## Teorema 3

*L'azione congiunta  $\sigma = (\theta, \{a_t, b_t\}_{t=1}^T, \{q_{vt}, d_{vt}\})$  è un equilibrio di Nash del DLG se e soltanto se è un'espansione per  $\theta$  e  $\theta$  è un punto KKT del DLP.*

- 1 Gioco di apprendimento a un livello
- 2 Gioco per reti neurali
- 3 Problema parziale e punti KKT**
- 4 Approfondimento per DLG

Generalizziamo: consideriamo una partizione  $P$  di  $V - I$  tale che per ogni  $\rho \in P$ , se  $u, v \in \rho$  e  $u \leq v$  allora  $v \leq u$ .

Sia  $E_\rho = \bigcup_{v \in \rho} E_v$ ,  $\Theta_\rho \subset \mathbb{R}^{E_\rho}$  e  $\Theta = \prod_{\rho \in P} \Theta_\rho$ .

Lasciamo invariati lo spazio delle azioni degli zanni e dell'antagonista, ma ora ogni protagonista controlla una parte del nodo  $\rho$ .

Se la partizione è quella dei singoletti, si torna al caso base.

## Definizione 11

*Sia  $u : \mathbb{R}^{E_\rho} \rightarrow \mathbb{R}$  una funzione affine. Trovare l'insieme  $\operatorname{argmax}_{\theta_\rho \in \Theta_\rho} u(\theta_\rho)$  è chiamato problema parziale in  $\rho \in P$ .*

## Definizione 11

*Sia  $u : \mathbb{R}^{E_\rho} \rightarrow \mathbb{R}$  una funzione affine. Trovare l'insieme  $\operatorname{argmax}_{\theta_\rho \in \Theta_\rho} u(\theta_\rho)$  è chiamato problema parziale in  $\rho \in P$ .*

Per ogni  $\rho \in P$ , siano  $H_\rho \subset \mathbb{R}^{E_\rho}$  e  $J_\rho \subset \mathbb{R}^{E_\rho}$  insiemi finiti di funzioni differenziabili continue. Allora, possiamo porre che  $\Theta_\rho$  sia l'insieme di tutti  $\theta_\rho \in \mathbb{R}^{E_\rho}$  tale che per ogni  $h \in H_\rho$ ,  $h(\theta_\rho) = 0$ , e per ogni  $j \in J_\rho$ ,  $j(\theta_\rho) \leq 0$ .

## Definizione 12

*Diciamo che  $\theta_\rho$  è un punto KKT per il problema parziale in  $\rho \in P$  se  $\theta_\rho \in \Theta_\rho$  e esistono moltiplicatori  $\mu_j \geq 0$  e  $\lambda_h \in \mathbb{R}$  tali che:*

$$\nabla u(\theta_\rho) = \sum_{j \in J_\rho} \mu_j \nabla j(\theta_\rho) + \sum_{h \in H_\rho} \lambda_h \nabla h(\theta_\rho)$$

$$\mu_j j(\theta_\rho) = 0 \text{ per ogni } j \in J_\rho$$

## Definizione 13

*Se per ogni  $\rho \in P$ , gli elementi di  $H_\rho$  e  $J_\rho$  sono affini allora si parla di restrizione parziale affine. Se, invece, per ogni  $\rho \in P$ , gli elementi di  $H_\rho$  sono affini e quelli di  $J_\rho$  sono convessi allora si parla di restrizione parziale di Slater.*



## Definizione 13

*Se per ogni  $\rho \in P$ , gli elementi di  $H_\rho$  e  $J_\rho$  sono affini allora si parla di restrizione parziale affine. Se, invece, per ogni  $\rho \in P$ , gli elementi di  $H_\rho$  sono affini e quelli di  $J_\rho$  sono convessi allora si parla di restrizione parziale di Slater.*

## Teorema 4

*Mettiamoci nelle ipotesi della restrizione parziale affine o di Slater. Allora un punto è di minimo globale se e soltanto se è un punto KKT.*

- 1 Gioco di apprendimento a un livello
- 2 Gioco per reti neurali
- 3 Problema parziale e punti KKT
- 4 Approfondimento per DLG

## Definizione 14

*Sia  $\sigma = (\theta, \{a_t, b_t\}_{t=1}^T, \{q_{vt}, d_{vt}\}_{t=1}^T)$  un'azione congiunta e  $v \in V$ . Se  $f_v$  è convessa e differenziabile, si dice che lo zanni di  $v$  è ragionevole per  $\sigma$  se  $\forall t \in \{1, \dots, T\}$ , vale che:*

$$\begin{cases} q_{vt} = f'_v(\sum_{u:(u,v) \in E} c_t(u, \theta) \theta(u, v)) \\ f_v(\sum_{u:(u,v) \in E} c_t(u, \theta) \theta(u, v)) = d_{vt} + q_{vt}(\sum_{u:(u,v) \in E} c_t(u, \theta) \theta(u, v)). \end{cases}$$

## Definizione 14

*Sia  $\sigma = (\theta, \{a_t, b_t\}_{t=1}^T, \{q_{vt}, d_{vt}\}_{t=1}^T)$  un'azione congiunta e  $v \in V$ . Se  $f_v$  è convessa e differenziabile, si dice che lo zanni di  $v$  è ragionevole per  $\sigma$  se  $\forall t \in \{1, \dots, T\}$ , vale che:*

$$\begin{cases} q_{vt} = f'_v(\sum_{u:(u,v) \in E} c_t(u, \theta) \theta(u, v)) \\ f_v(\sum_{u:(u,v) \in E} c_t(u, \theta) \theta(u, v)) = d_{vt} + q_{vt}(\sum_{u:(u,v) \in E} c_t(u, \theta) \theta(u, v)). \end{cases}$$

## Definizione 15

*In maniera analoga, se la funzione perdita  $l$  è convessa e differenziabile nel primo termine, allora l'antagonista è ragionevole se  $\forall t \in \{1, \dots, T\}$ :*

$$\begin{cases} a_t = \nabla l_t(z)|_{z=c_t(o, \theta)} \\ a_t^T c_t(o, \theta) + b_t = l_t(c_t(o, \theta)). \end{cases}$$

## Teorema 5

*Siano dati un insieme finito  $S$ , un ordinamento parziale  $\leq$  su  $S$  e  $X \subset S$ . Se  $\forall s \in S$  si ha che  $\{s' \in S : s' < s\} \subset X \implies s \in X$ , allora  $X = S$ . Questa, in teoria degli insiemi, è chiamata induzione forte su un insieme parzialmente ordinato.*

Da questo lemma, riusciamo a dimostrare uno dopo l'altro risultati cruciali riguardanti le azioni e le utilità degli zanni e antagonista. Supponiamo che  $\forall v \in V$ ,  $f_v$  sia convessa e differenziabile e la funzione perdita  $l$  sia convessa differenziabile nel primo termine. Sia  $\leq$  l'ordinamento parziale generato dal grafo diretto aciclico della rete neurale. Fissiamo  $v \in V$ .

- ① Data un'azione congiunta  $\sigma$  dove  $\forall u \leq v$ , lo zanni di  $u$  è ragionevole per  $\sigma$ , allora  $U_{tv}^s(\sigma) = c_t(v, \theta)$ ;
- ② Data un'azione congiunta  $\sigma$  dove tutti gli zanni e l'antagonista sono ragionevoli, allora  $U_t^a(\sigma) = l_t(c_t(o, \theta))$ , per ogni dato di allenamento  $x_t$ ;
- ③ data un'azione congiunta  $\sigma$  dove  $\forall u \leq v$  (tranne al più  $v$ ), lo zanni di  $u$  è ragionevole per  $\sigma$ , allora l'unica migliore risposta per lo zanni in  $v$  è di essere ragionevole.
- ④ Data un'azione congiunta  $\sigma$  dove tutti gli zanni sono ragionevoli, allora l'unica migliore risposta per l'antagonista è di essere ragionevole.

In queste ipotesi, quindi, gli zanni e l'antagonista agiscono in maniera ragionevole se e soltanto se giocano la loro migliore risposta. Vediamo i protagonisti.

## Lemma 5

*Assumiamo che  $\forall v \in V$ ,  $f_v$  sia convessa e differenziabile e la funzione perdita  $l$  sia convessa differenziabile nel primo termine. Data un'azione congiunta  $\sigma = (\theta, \{a_t, b_t\}_{t=1}^T, \{q_{vt}, d_{vt}\}_{t=1}^T)$  dove tutti gli zanni e l'antagonista sono ragionevoli, allora se  $U^P$  è l'utilità del protagonista, vale:*

$$\nabla_{\theta} U^P(\sigma) = -\nabla_{\theta} L(\theta).$$

# Dimostrazione Lemma

- 1 Mostriamo che  $\nabla_{\theta} U_t^p(\sigma) = -\nabla_{\theta} l_t(c_t(o, \theta))$ .
- 2 Partiamo vedendo  $\frac{\partial U_t^p(\sigma)}{\partial U_{tv}^s(\sigma)} = -\frac{\partial l_t(c_t(o, \theta))}{\partial c_t(v, \theta)}$ :
  - per  $o \in O$  viene subito dalla definizione di utilità ( $U_t^p(\sigma) = -b_t - \sum_{k=1}^n a_{kt}(U_t^s(o_k))$ ) e ragionevolezza dell'antagonista ( $a_{kt} = \frac{\partial l_t(c_t(o_k, \theta))}{\partial c_t(o_k, \theta)}$ ).
  - Applichiamo induzione forte non su  $\leq$  ma sull'ordine parziale opposto  $\sqsubseteq$  dato che siamo partiti dagli output. Usiamo ipotesi induttiva e la ragionevolezza degli zanni.



# Dimostrazione Lemma

Ora, consideriamo  $(u, v) \in E$ , allora:

$$\frac{\partial U_t^p(\sigma)}{\partial \theta(u, v)} = \frac{\partial U_t^p(\sigma)}{\partial U_{tv}^s(\sigma)} q_{tv} U_{tu}^s(\sigma) = -\frac{\partial l_t(c_t(o, \theta))}{\partial c_t(v, \theta)} q_{tv} U_{tu}^s(\sigma),$$

Usando sempre che gli zanni sono ragionevoli, si ha

$q_{vt} = f'_v(\sum_{u':(u',v) \in E} c_t(u', \theta) \theta(u', v))$  e  $U_{tu}^s(\sigma) = c_t(u, \theta)$ :

$$\frac{\partial U_t^p(\sigma)}{\partial \theta(u, v)} = -\frac{\partial l_t(c_t(o, \theta))}{\partial c_t(v, \theta)} f'_v\left(\sum_{u':(u',v) \in E} c_t(u', \theta) \theta(u', v)\right) c_t(u, \theta).$$

Dalla definizione di  $c_t(v, \theta)$  si ottiene che

$\frac{\partial c_t(v, \theta)}{\partial \theta(u, v)} = f'_v(\sum_{u':(u',v) \in E} c_t(u', \theta) \theta(u', v)) c_t(u, \theta)$ :

$$\frac{\partial U_t^p(\sigma)}{\partial \theta(u, v)} = -\frac{\partial l_t(c_t(o, \theta))}{\partial c_t(v, \theta)} \frac{\partial c_t(v, \theta)}{\partial \theta(u, v)} = -\frac{\partial l_t(c_t(o, \theta))}{\partial \theta(u, v)}.$$

## Definizione 16

*Sia  $P(u, v)$  l'insieme di tutti i percorsi da  $u$  in  $v$ , e per ogni percorso  $p$  sia  $|p|$  il numero di nodi del percorso.*

## Definizione 16

*Sia  $P(u, v)$  l'insieme di tutti i percorsi da  $u$  in  $v$ , e per ogni percorso  $p$  sia  $|p|$  il numero di nodi del percorso.*

## Lemma 6

$$\frac{\partial U^p(\sigma)}{\partial \theta(u, v)} = -\frac{1}{T} \sum_{t=1}^T \sum_{k=1}^n \sum_{p \in P(v, o_k)} U_{tu}^s(\sigma) q_{t, p_{|p|}} a_{kt} \prod_{j=1}^{|p|-1} \theta(p_j, p_{j+1}) q_{t, p_j}$$

## Definizione 17

*Sia  $\rho \in P$ , definiamo  $U_{\rho,\sigma}^p : \mathbb{R}^{E_\rho} \rightarrow \mathbb{R}$  tale che  $U_{\rho,\sigma}^p(\theta_\rho)$  è l'utilità del protagonista su  $\rho$  se decide unilateralmente di giocare  $\theta_\rho$  invece che  $\sigma$ .*

## Definizione 17

*Sia  $\rho \in P$ , definiamo  $U_{\rho,\sigma}^p : \mathbb{R}^{E_\rho} \rightarrow \mathbb{R}$  tale che  $U_{\rho,\sigma}^p(\theta_\rho)$  è l'utilità del protagonista su  $\rho$  se decide unilateralmente di giocare  $\theta_\rho$  invece che  $\sigma$ .*

## Lemma 7

*$U_{\rho,\sigma}^p$  è una funzione affine.*

# Dimostrazione Lemma

Sia  $\sigma|_{\rho} : \Theta_{\rho} \rightarrow \Sigma$  t.c.  $\sigma|_{\rho}(\tilde{\theta})$  è lo stesso di  $\sigma$  eccetto l'azione del protagonista su  $\rho$  è rimpiazzata da  $\tilde{\theta}$ . Vale quindi  $\forall (u, v) \in E_{\rho}$ :

$$U_{\rho, \sigma}^p(\tilde{\theta}) = U^p(\sigma|_{\rho}(\tilde{\theta})) \implies \frac{\partial U_{\rho, \sigma}^p(\tilde{\theta})}{\partial \tilde{\theta}_{(u, v)}} = \frac{\partial U^p(\sigma|_{\rho}(\tilde{\theta}))}{\partial \tilde{\theta}_{(u, v)}}$$

Dunque:

$$\frac{\partial U^p(\sigma|_{\rho}(\tilde{\theta}))}{\partial \tilde{\theta}_{(u, v)}} = -\frac{1}{T} \sum_{t=1}^T \sum_{k=1}^n \sum_{p \in P(v, o_k)} U_{tu}^s(\sigma|_{\rho}(\tilde{\theta})) q_{t, p|p|} a_{kt} \prod_{j=1}^{|p|-1} \theta(p_j, p_{j+1}) q_{t, p_j}$$

Per ipotesi di partizione, né  $u$  né un nodo "antenato" sono in  $\rho$ . Allora,  $U_{tu}^s(\sigma|_{\rho}(\tilde{\theta})) = U_{tu}^s(\sigma)$ . Quindi, la derivata parziale è una funzione solo di  $\sigma \implies$  derivata parziale costante lungo ogni coordinata  $\implies$  affine.

## Lemma 8

*Data un'azione dei protagonisti  $\theta$ , esiste un'unica azione congiunta  $\sigma = (\theta, \{a_t, b_t\}_{t=1}^T, \{q_{vt}, d_{vt}\})$  (la scelta congiunta espansa) nella quale gli zanni e l'antagonista giocano le loro migliori risposte a  $\theta$ . Non solo,  $U_p(\sigma) = -L(\theta)$ ,  $\nabla_{\theta} U^p(\sigma) = -\nabla L(\theta)$ , e dato un protagonista in  $\rho \in P$ , se teniamo le scelte di ogni altro agente fisse,  $U^p(\sigma)$  è una funzione affine rispetto alla strategia del protagonista in  $\rho$ .*

## Dimostrazione Lemma

- Scelta congiunta espansa:** Fissiamo azione arbitraria  $\sigma_0$ .  
 Sia  $\sqsubseteq$  un'estensione lineare di  $\leq$ . Così si ha  $v_1, \dots, v_{|V|}$  tali che  $v_k \sqsubseteq v_{k+1}$ . Usiamo ricorsione:  $\sigma_k$  è uguale a  $\sigma_{k-1}$ , tranne per lo zanni in  $v_k$  che gioca la risposta migliore a  $\sigma_{k-1}$ . Usando lemma precedente, per ogni zanni al passo  $k$  esiste la risposta ragionevole ed è unica. Al passo  $|V|$  abbiamo un'azione congiunta dove tutti gli zanni sono ragionevoli.  
 Per lemma esiste ed è unica la risposta ottima per l'antagonista ed è quella nella quale gioca in maniera ragionevole.
- $U_p(\sigma) = -L(\theta)$ : gli zanni e l'antagonista sono ragionevoli allora  $U_t^a(\sigma) = I_t(c_t(o, \theta))$ . Se ne fa la media ricordando che  $U^p = -U^a$ .





## Teorema 6

*Assumiamo che per ogni  $v \in V$ ,  $f_v$  è convessa e differenziabile e la perdita  $l$  è convessa e differenziabile rispetto alla prima componente. Per ogni punto KKT  $\theta \in \Theta$ , c'è un equilibrio di Nash dove l'azione congiunta dei protagonisti è  $\theta$ . Viceversa, per ogni equilibrio di Nash dove l'azione congiunta dei protagonisti è  $\theta$ , allora  $\theta$  è un punto KKT.*

# Dimostrazione Teorema

Basta fare la freccia  $\implies$ , l'altra si ottiene percorrendo la dimostrazione in senso opposto.

Scegliamo  $\sigma$  azione espansa di  $\theta$  (tutti gli zanni e l'antagonista sono ragionevoli, dunque sappiamo già che stanno giocando la loro migliore risposta).

Mostriamo che che per ogni  $\rho \in P$ , il protagonista in  $\rho$  sta giocando la sua risposta migliore, cioè se  $U^P(\sigma)$  è vista come una funzione dei valori di  $\theta$  su  $(u, v) \in E_\rho$ , allora il  $\theta$  scelto in  $\sigma$  è un massimo globale.

Strategia: trasportiamo le condizioni *KKT* del problema completo nelle condizioni *KKT* per il problema parziale  $U_{\rho, \sigma}$ .

# Dimostrazione Teorema

Ora, le condizioni *KKT* sulla perdita  $L$  implicano che esistono i moltiplicatori *KKT*  $\mu_{j,\rho}$  e  $\lambda_{h,\rho}$  tali che:

$$-\nabla L(\theta) = \sum_{\rho \in P} \sum_{j \in J_\rho} \mu_{j,\rho} \nabla j(\theta) + \sum_{\rho \in P} \sum_{h \in H_\rho} \lambda_{h,\rho} \nabla h(\theta)$$

$$\mu_{j,\rho} j(\theta) = 0 \quad \forall \rho \in P, j \in J_\rho$$

Ricordando che  $\nabla_\theta U^P(\sigma) = -\nabla L(\theta)$ :

$$\nabla_\theta U^P(\sigma) = \sum_{\rho \in P} \sum_{j \in J_\rho} \mu_{j,\rho} \nabla j(\theta) + \sum_{\rho \in P} \sum_{h \in H_\rho} \lambda_{h,\rho} \nabla h(\theta)$$

$$\mu_{j,\rho} j(\theta) = 0 \quad \forall \rho \in P, j \in J_\rho$$

## Dimostrazione Teorema

Fissiamo  $\rho \in P$ . Sia  $\theta_\rho \in \Theta_\rho$  l'azione del protagonista su  $\rho$  in  $\theta$ .  
Restringendoci su  $E_\rho$ , solo le restrizioni in  $J_\rho$  e  $H_\rho$  varieranno:

$$\begin{aligned}\nabla_{\theta_\rho} U^P(\sigma) &= \sum_{j \in J_\rho} \mu_{j,\rho} \nabla j(\theta) + \sum_{h \in H_\rho} \lambda_{h,\rho} \nabla h(\theta) \\ \mu_{j,\rho} j(\theta) &= 0 \quad \forall j \in J_\rho\end{aligned}$$

Ora, ha senso sostituire  $U^P(\sigma)$  con  $U_{\rho,\sigma}^P$ :

$$\begin{aligned}\nabla_{\theta_\rho} U_{\rho,\sigma}^P(\theta_\rho) &= \sum_{j \in J_\rho} \mu_{j,\rho} \nabla j(\theta_\rho) + \sum_{h \in H_\rho} \lambda_{h,\rho} \nabla h(\theta_\rho) \\ \mu_{j,\rho} j(\theta_\rho) &= 0 \quad \forall j \in J_\rho\end{aligned}$$

Queste sono le condizioni *KKT* per essere massimo locale ma  $U_{\rho,\sigma}^P$  è affine  $\implies$  punto di massimo globale  $\implies$  ciascun protagonista non può unilateralmente migliorare su  $\sigma$ .

# Bibliografia

- [1] Dale Schuurmans e Martin Zinkevich. *Deep Learning Games*, 2016.
- [2] S. Boyd e L. Vandenberghe. *Convex Optimization*. Cambridge U. Press, 2004.
- [3] N. Cesa-Bianchi e G. Lugosi. *Prediction, learning, and games*. Cambridge University Press, 2006.
- [4] W. Karush. *Minima of functions of several variables with inequalities as side constraints*. Master' s thesis, Univ. of Chicago, Chicago, Illinois, 1939.
- [5] H. Kuhn e A. Tucker. Nonlinear programming. *In Proceedings of 2nd Berkeley Symposium*, pages 481–492. University of California Press, 1951.

# Grazie per l'attenzione!